

O CANIVETE SUÍÇO DO BIG DATA

ELIÉZER ZARPELÃO

# ELIÉZER ZARPELÃO - ACADÊMICO

- X Tec. Informática SI COTUCA/Unicamp
- X Graduado em Sistemas de Informação ICMC/USP
- Especialista em Eng. de Software IC/Unicamp
- Futuro mestre IC/Unicamp
  - Futebol + Machine Learning













## PROFISSIONAL

- Manager Tech Architect Avanade (Habemus Vagas)
- X Arquiteto de Soluções ZarpSystem
- X Analista de Sistemas FEM Unicamp
- X Docente/Coordenador de Curso IESCAMP
- ✗ Docente − UNAERP
- \* Tecnologia desde 2005 (1996)

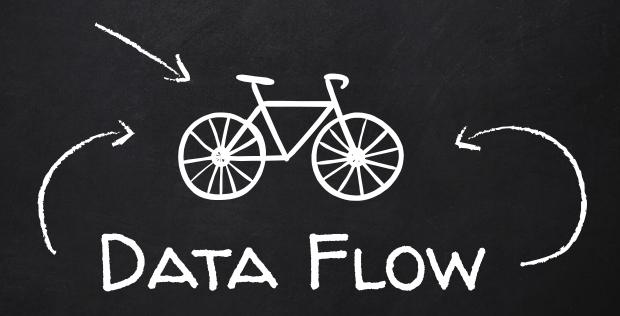












O que são? Onde vivem? O que comem?





Mover conteúdo de "A" para "B" Logs, HTTP, XML, CSV, Imagens, Vídeos, etc e etc





SUAVE... #SQN

## HOW STANDARDS PROLIFERATE: (SEE: A/C CHARGERS, CHARACTER ENCODINGS, INSTANT MESSAGING, ETC.)

SITUATION: THERE ARE 14 COMPETING STANDARDS.



500N:

SITUATION: THERE ARE 15 COMPETING STANDARDS.



<u>Dados</u>

Padrões

**Formatos** 

Protocolos

Veracidade

Validade

Schemas

**Particionamento** 

<u>Infraestrutura</u>

Entrega "Exactly Once"

Segurança

Gestão de acesso

Rede

<u>Pessoas</u>

Compliance

Pessoa / Time / Grupo

Mudança nos consumidores

Alterações de requisitos

Entrega "Exactly Once"

66

"Provides a way to prioritize data flows more effectively and get rid of artificial delays in identifying and transmitting critical information" Joseph L. Witt



# APACHE NIFI

- X Plataforma open-source para construção e gestão de fluxos de dados (low-code)
- Escalável, segura e tolerante a falhas
- X Interface Web e API para gestão e monitoramento dos fluxos
- X Fluxos de dados podem ser alterados em tempo de execução

## FLOW FILE

- Objeto que se move através do fluxo
- X Coração do NiFi
- X Atributos (chave/valor)
- X Apontador para conteúdo

#### HTTP HEADER

Request URL: https://www.google.com/

Request Method: GET

Remote Address: 172.217.29.164:443

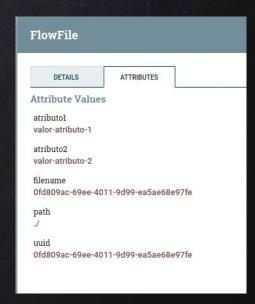
Status Code: 200 0K (?

Version: HTTP/2

#### HTTP PAYLOAD

<!doctype html>chtml itemscope="" itemtype="http://schema.org/WebPage" lang="en-BR"><head><meta
document.documentEtement.addEventListener("submit",function(b){var a;if(a=b.target){var c=a.get4
var e=window,performancervar g=function(a,b,c,d){a.addEventListener?a.removeEventListener(b,c,d)
var b=[function(){google.tick&6google.tick("load","dcl")}];google.dclc=function(a){b.length?b.pu
var b=[];google.jsc=[xx:b.x:function(a){b.push(a)},mm:[],m:function(a){google.jsc.mm.length]|(gc
var f=this[];getf,h=Date.now;</pre>

var x{}:var as=function(a,c){if(null===c)return!l;if("contains"in a&&!==c.nodeType!return a.cor
var I=function(){this.h=this.a=null}, %=function(a,c){var d=jd.a=a;d.h=c:return d};l,prototype.c,
var O=function(){this.o=[]:this.a=[]:this.g=[]:this.j={}:this.h=null:this.i=[]:N(this,"\_custom")
4==b.button[|b.shiftKey)]m="clickmod":else{var l=b.which||b.keyCode;ca&3==L&&(l=13);if(13)=L&E
c.tagName).toUpperCase(), e=32=(b.which||b.keyCode)&S\*CHECKBOX\*"!=p][[ez0,b].n=c.tagName.toUppe
m]||"mouseout"==b.type&&"mouseleave"==m]||e&&(e===k||aa(k,e))]l.action="".l.actionEement=null:elwidow.rwt=function(){eturn(s);}).catl(this);(function(){sindwo\_isanvt=function(){eturn(s);}).var
awindow.location.b=a.href.indexOf("#"):if(0<=b){var c=a.href.substring(b+l);/("|&)=/.test(c)break a;c=c[e]}a=a[a.length-l];d=c[a];b=b(d);b!=d&Snull!=b&&h(c,a,{configurable:!0,writable:!tryf./\*</pre>





# PROCESSOR

- **X** Executa um trabalho
- X Roteamento, transformação...
- X Mais de 200 componentes...

	Obtem Arquivo via FTP GetFTP 1.11.4 org.apache.nifi - nifi-standard-nar	
In	<b>0</b> (0 bytes)	5 min
Read/Write	0 bytes / 0 bytes	5 min
Out	<b>0</b> (0 bytes)	5 min
Tasks/Time	0 / 00:00:00.000	5 min

# PROCESSORS













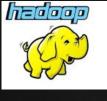


























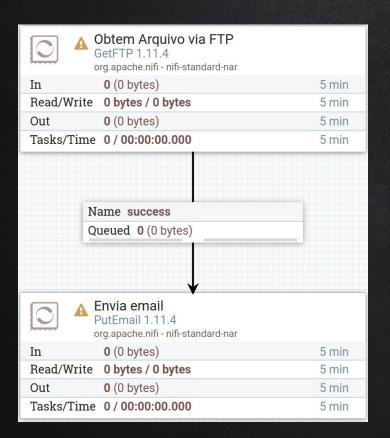






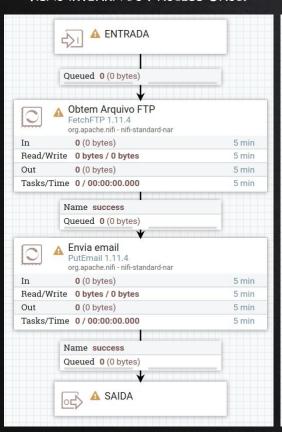


## CONNECTIONS

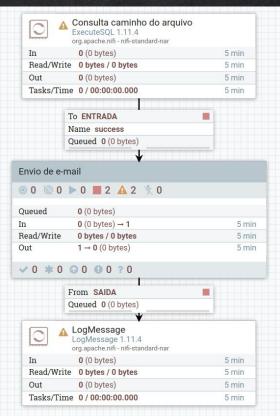


- X Conexão entre Processors
- \* Atua como fila

#### VISÃO INTERNA DO PROCESS GROUP



#### VISÃO EXTERNA DO PROCESS GROUP



## PROCESS GROUP

- Conjunto de processors e connections
- Envia e recebe dados via portas

# CONTROLLER SERVICE

X Recursos compartilhados no fluxo

CONEXÃO COM
BANCO DE
CACHE
CACHE
(REDIS)

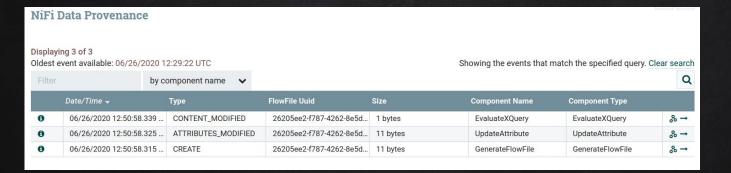
CREDENCIAIS
CLOUD

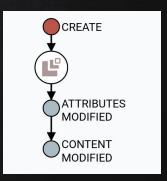
CONTEXTMAP
HTTP
(API)

...

## DATA PROVENANCE

X Caminho percorrido pelo FlowFile





<u>Operadores:</u> rastreamento, ciclo de vida <u>Governança:</u> Auditoria

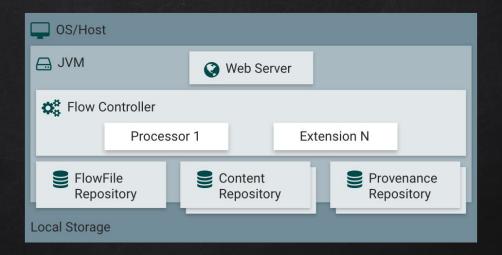
<u>Negócio:</u> Fontes de valor, Valores de investimento

# FLOW CONTROLLER

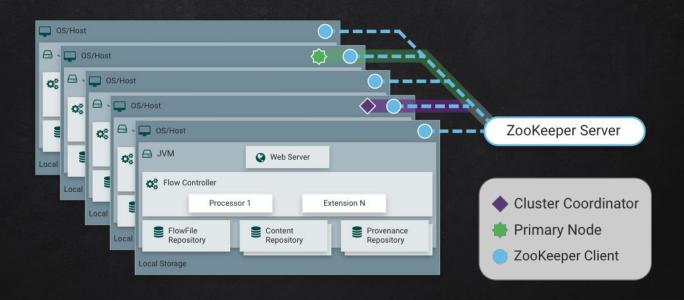
- X Orquestra como os processos se conectam e gerencia todas alocações que os processos usam.
- X Atua como broker facilitando a troca de FlowFiles entre os Processors



# ARQUITETURA



# ARQUITETURA - CLUSTER





# CALM AND DEMO ON



{JSON}
New York Times Best Sellers
6 MB

#### Requisitos do "cliente"

- Gravar todos registros em um banco MySQL e no Elastic
- Enviar por email os links da Amazon dos que ficaram por mais de 20 semanas na lista







# FUNCIONALIDADES

GARANTIA DE ENTREGA

BACK PRESSURE

PRIORIZAÇÃO DE FILAS TEMPLATES DE FLUXOS

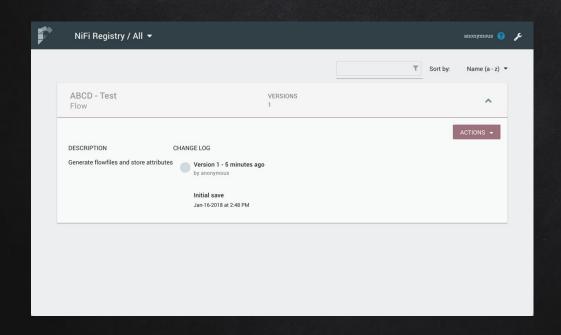
DATA PROVENANCE

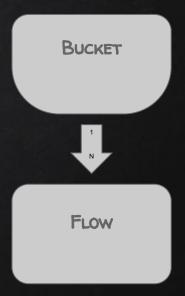
EXTENSIBILIDADE

ESCALABILIDADE

SEGURANÇA

# NIFI REGISTRY





# APRENDA MAIS

- Site Oficial: https://nifi.apache.org/
- X Idéias e sugestões: https://issues.apache.org/jira/browse/nifi
- **X** Twitter: @apachenifi
- ✗ Telegram: https://t.me/nifibrasil



Perguntas?

https://github.com/elizarp/conaaed-2021



- x eliezer.zarpelao@gmail.com
- https://www.linkedin.com/in/eliezerzarpelao/
- \* http://eliezerzarpelao.eti.br
- @eliezerzarpelao (Twitter/Instagram)



#### CREDITS

Special thanks to all the people who made and released these awesome resources for free:

- Presentation template by <u>SlidesCarnival</u>
- X Photographs by <u>Unsplash</u>